

Paper阅读: HTAP Databases: What is New and What is Next


目录

- **一. 背景**
- **二. HTAP Databases**
 - a) 主行存储+内存列存储
 - b) 分布式行存储+列存储副本
 - c) 磁盘行存储+分布式列存储
 - d) 主列存储+增量行存储
- **三: HTAP 技术**
 - (1) 事务处理技术
 - (2) 分析处理技术
 - (3) 数据同步技术
 - (4) 查询优化技术
 - (5) 资源调度技术
- **四. 总结**

一. 背景

在最新一届国际数据库顶级会议 ACM SIGMOD 2022 上，来自清华大学的李国良和张超两位老师发表了一篇文章：《HTAP Database: What is New and What is Next》

主要 分享了HTAP的发展现状和未来趋势



二. HTAP Databases

HTAP数据库分为四类：（a）主行存储+内存列存储；（b）分布式行存储+列存储副本；（c）磁盘行存储+分布式列存储；以及（d）主列存储+增量行存储





Table 1: A Classification of State-Of-The-Art HTAP Databases based on the Storage Architecture

Category	HTAP databases	TP Throughput	AP Throughput	TP Scalability	AP Scalability	Isolation	Freshness
Primary Row Store + In-Memory Column Store	Oracle Dual-Format [19], SQL Server [20], DB2 BLU [39]	High	High	Medium	Low	Low	High
Distributed Row Store + Column Store Replica	TiDB [18], SingleStore [44]	Medium	Medium	High	High	High	Low
Disk Row Store + Distributed Column Store	MySQL Heatwave [31]	Medium	Medium	Medium	High	High	Medium
Primary Column Store + Delta Row Store	SAP HANA [43]	Medium	High	Low	Medium	Low	High

a) 主行存储+内存列存储


这类 HTAP 数据库利用主行存储作为 OLTP 工作负载的基础，并使用内存列存储处理 OLAP 工作负载。因此可以有效地处理数据更新。更新也会附加到增量存储中，增量存储将合并到列存储中。例如，Oracle 内存双格式数据库结合了基于行的缓冲区和基于列的内存压缩单元 (IMCU) 来一起处理 OLTP 和 OLAP 工作负载。文件和更改缓存存在快照元数据单元 (SMU) 中。另一个例子是 SQL Server，它在 Hekaton 引擎中的内存表上开发了列存储索引 (CSI)，以实现实时分析处理。

case: Oracle Dual-Format



- SIMD: 单指令多数据
- Vector Group By: 向量化

case: SQL Server




- Persistent Column Store: 持久化列存
- Updatable: 可更新

b) 分布式行存储+列存储副本

此类依赖于分布式架构来支持 HTAP。主节点在处理事务请求时将日志异步复制到从节点。主存储为行存储，选择一些从节点作为列存储服务器进行查询加速。事务以分布式方式处理以实现高可扩展性；复杂查询在具有列存储的服务器节点中执行。

case TiDB




TiFlash 服务器：列存储数据，主要用于加速分析处理

c) 磁盘行存储+分布式列存储

这种数据库利用基于磁盘的 RDBMS 和分布式内存列存储 (IMCS) 来支持 HTAP。RDBMS 保留了 OLTP 工作负载的全部内容，并且深度集成了 IMCS 集群以加速查询处理。列数据从行存储中提取，热数据驻留在 IMCS 中，冷数据将被驱逐到磁盘。例如，MySQL Heatwave 将 MySQL 数据库与称为 Heatwave 的分布式 IMCS 集群相结合，以实现实时分析。事务在 MySQL 数据库中完全执行。经常访问的列将被加载到 Heatwave，当复杂查询进来时，可以下推到 IMCS 引擎进行查询加速。

case: MYSQL Heatwave

将 MySQL 数据库与分布式 IMCS 集群（称为 Heatwave）结合，实现实时分析。事务完全在 MySQL 中执行，频繁访问的列会被加载到 Heatwave 中。复杂查询可以下推到 IMCS 引擎执行。



MySQL HeatWave 工作原理：

- RAPID 引擎支持语句中相关函数；
- RAPID 引擎执行时间评估少于 InnoDB 的执行时间。

当同时满足以上两个条件时，将由 RAPID 引擎，也就是 MySQL HeatWave 来处理相关业务请求。

在启用 MySQL HeatWave 插件后，对于接收到的请求，MDS 会通过两个条件来判断该请求是否走 RAPID 引擎，MySQL HeatWave 所使用的引擎是 RAPID，在研发阶段 MySQL HeatWave 的名字就是“RAPID”。

同步方式：

MDS 会根据如下策略对数据进行同步：

- 每 200 ms；
- 当变更传输缓冲区达到 64MB 时；
- 在 MDS 中，经过 DML 变更的数据被后续的 HeatWave 查询需要读取时


d) 主列存储+增量行存储

这类数据库使用主列存储作为 OLAP 的基础，并通过增量行存储处理 OLTP。整个数据保存在主列存储中，数据更新追加到基于行的增量存储中。


由于列存储针对读取进行了高度优化，因此OLAP 性能高。但由于只有一个增量行存储处理 OLTP，OLTP 可扩展性较低。

case: SAP HANA

它将内存数据存储分为三层：L1-delta、L2-delta 和 Main。L1-delta 以行格式保存数据更新，当达到阈值时，数据被迫加到 L2-delta，L2-delta 将数据转换为列格式，然后合并到主列存储中，最终列数据被持久化到磁盘。



case: Hyper (Column)



三：HTAP 技术

(1) 事务处理技术

HTAP 中的 OLTP 工作负载通常在行存储上处理，但不同架构采用不同技术：

- MVCC + 日志：依赖多版本并发控制和日志记录，效率高但可扩展性低。
- 2PC + Raft + 日志：基于分布式架构，使用两阶段提交和 Raft 共识算法，具备高可扩展性但效率较低。

(2) 分析处理技术

OLAP 工作负载使用列式处理技术，如压缩数据上的聚合和 SIMD 指令：

- 内存增量 + 列扫描：扫描内存中的增量数据，新鲜度高。
- 日志增量 + 列扫描：扫描磁盘中的日志增量数据，新鲜度低。
- 纯列扫描：仅扫描列数据，效率高但新鲜度低。

(3) 数据同步技术

为了减少查询时的增量数据扫描成本，系统会定期将增量数据合并到主列存储：

- 内存增量合并
- 从主行存储重建列存储

(4) 查询优化技术

- 列选择：根据历史工作负载自动选择热列加载到内存。
- 混合行/列扫描：基于成本选择执行路径。
- CPU/GPU 加速：利用异构硬件加速 HTAP，但可能牺牲 TP 吞吐量。

(5) 资源调度技术

- 工作负载驱动调度：根据运行时性能动态调整 OLTP/OLAP 线程数。
- 新鲜度驱动调度：根据数据新鲜度切换执行模式（隔离 vs 共享）。

四. 总结

任务类型	关键技术	HTAP 数据库/原型系统	优点	缺点
事务处理	MVCC + 日志	Oracle Dual-Format [19], SQL Server [20], DB2 BLU [39], MySQL Heatwave [31], SAP HANA [43]	高效率	可扩展
	2PC + Raft + 日志	TiDB [18]	高可扩展性	效率低
分析处理	内存增量 + 列扫描	Oracle Dual-Format [19], SQL Server [20], DB2 BLU [39], MySQL Heatwave [31], SAP HANA [43]	数据新鲜度高	内存占
	基于日志的增量 + 列扫描	TiDB [18]	可扩展性高	数据新
	列扫描	SingleStore [44]	高效率	数据新
数据同步	内存增量合并	Oracle Dual-Format [19], SQL Server [20], DB2 BLU [39], MySQL Heatwave [31], SAP HANA [43]	高效率	可扩展
	基于日志的增量合并	TiDB [18]	可扩展性高	合并成
	从主行存储重建列存储	SingleStore [44], Oracle Dual-Format [19]	内存占用小	加载成
查询优化	内存列选择	Oracle 21c [33], MySQL Heatwave [31]	内存利用率高	分析时
	混合行/列扫描	TiDB [18], SQL Server [13, 20]	分析处理吞吐量高	搜索空
	HTAP 的 CPU/GPU 加速	RateupDB [22], Caldera [5]	分析处理吞吐量高	事务时
资源调度	基于新鲜度的 HTAP 调度	RDE [40]	数据新鲜度高	吞吐量
	基于工作负载的 HTAP 调度	SAP HANA [43], Siper [45]	吞吐量高	数据新